UCZENIE GŁĘBOKIE I JEGO ZASTOSOWANIE

SPRAWOZDANIE KOŃCOWE Z LABORATORIÓW 03–07 ORAZ MINI-PROJEKTU

Autor: Kacper Sukiennik
Numer indeksu: 81783
Kierunek: Informatyka, studia II stopnia, specjalność AI
Semestr: III
Prowadząca: dr inż. Natalia Piórkowska
Data: 22 października 2026 r.

Wyniki eksperymentów: Google Colab | TensorFlow / Keras / PyTorch / scikit-learn

1 Cel i zakres sprawozdania

Celem opracowania jest zestawienie rezultatów uzyskanych w laboratoriach 03–07 oraz sprawdzenie osobnej hipotezy dotyczącej wpływu Dropout na skuteczność klasyfikacji sieci MLP. Wnioski sformułowano na podstawie wyników zapisanych w notebookach, a nie wartości przykładowych.

1.1. Zakres badań

Część	Zakres eksperymentów	Źródło wyników
Lab 03	Keras: klasyfikacja, regresja, regularyzacja	Lab03 .ipynb
Lab 04	CNN, CIFAR-10, MobileNetV2	Lab04 .ipynb
Lab 05	PyTorch: modele tabelaryczne i ocena	Lab05 .ipynb
Lab 06	PCA, autoenkodery, klasteryzacja	Lab06 .ipynb
Lab 07	VAE, DCGAN, analiza generowania	Lab07 .ipynb
Mini-projekt	MLP i Dropout na Breast Cancer Wisconsin	Mini_projekt .ipynb

1.2. Zasady analizy

Dla zadań nadzorowanych przyjęto metryki właściwe dla problemu (accuracy, ROC-AUC, F1 albo MAE/RMSE). Dla metod bez nadzoru wykorzystano błędy rekonstrukcji (MSE), metryki klasteryzacji (ARI/NMI) i pomocnicze oceny różnorodności. Wyniki pochodzą z różnych zbiorów i podziałów, dlatego bezpośrednie porównania dotyczą wyłącznie modeli testowanych w tym samym eksperymencie.

W mini-projekcie przygotowanie danych wykonywano po podziale na trening, walidację i test; standaryzację dopasowano wyłącznie do treningu. Porównanie wykonano dla trzech ziaren losowości: 11, 42 i 73. Osobno zbadano dobór progu decyzyjnego na walidacji.

1.3. Zapisana konfiguracja mini-projektu

Oprogramowanie	Wersja / parametr
Python	3.13.16
PyTorch	2.11.0+cpu
scikit-learn	1.6.1
NumPy	2.1.3
Urządzenie	CPU

Pełne wersje bibliotek i przebiegi eksperymentów znajdują się w dołączonych notebookach. Źródło danych i biblioteki: [4–6].

2 Laboratorium 03 — Keras

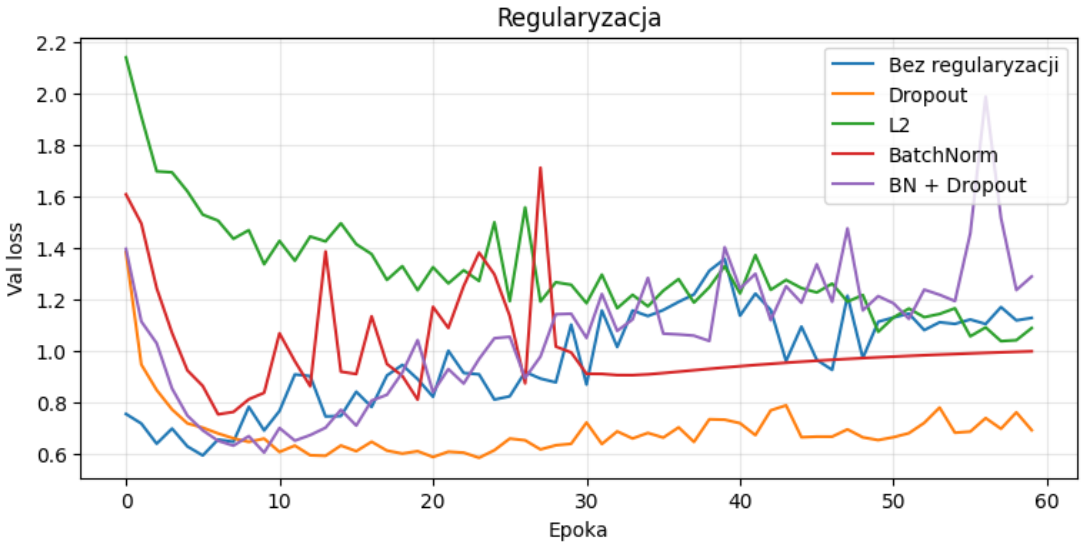
2.1. Regresja i klasyfikacja

Model regresyjny	MAE	RMSE
Średnia	0,905	1,145
Regresja liniowa	0,533	0,750
MLP	0,352	0,522

Sieć MLP osiągnęła najniższy błąd spośród porównywanych metod regresji dla California Housing. MAE i RMSE są wyrażone w jednostkach celu (100 tys. USD). Różnice te odnoszą się do tego samego podziału danych użytego w notebooku. W klasyfikacji Fashion-MNIST zastosowano softmax i śledzono krzywe uczenia.

2.2. Optymalizacja i regularyzacja

Optymalizator	Najlepsza val_accuracy
SGD	0,8354
SGD + momentum	0,8735
RMSprop	0,8831
Adam	0,8818



Rysunek 1. Walidacyjna funkcja straty w pięciu wariantach regularyzacji (Lab 03, zad. 5.2).

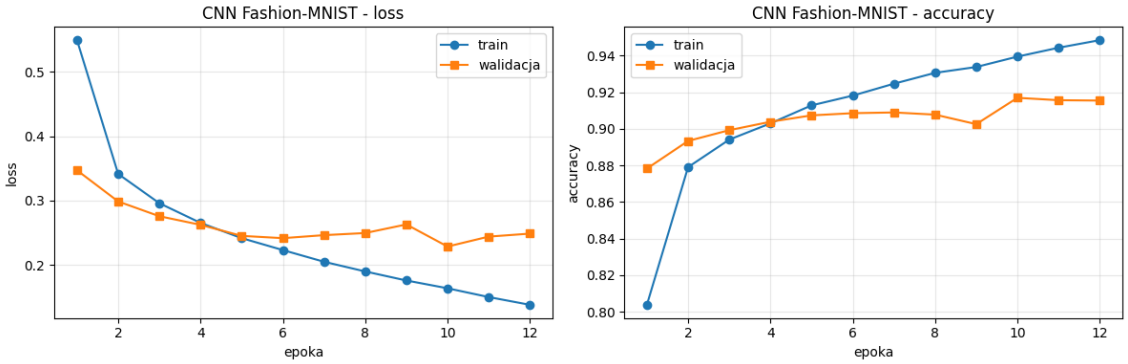
W badanym przebiegu Dropout osiągnął najlepszą walidacyjną dokładność 0,8227 i lukę train–val 0,1061, podczas gdy BatchNorm: odpowiednio 0,8144 oraz 0,1874. Hipoteza o mniejszym przeuczeniu po zastosowaniu Dropout znajduje tu częściowe wsparcie, lecz hipoteza o niższej początkowej stracie BatchNorm nie potwierdziła się. Możliwe usprawnienie: porównać harmonogramy learning rate przy stałym podziale danych.

3 Laboratorium 04 — CNN i transfer learning

3.1. CNN kontra MLP na Fashion-MNIST

Model	Parametry	Accuracy (test)	Czas (s)
MLP	235 146	0,8709	18,1
CNN	421 642	0,9090	31,3

Weryfikowana hipoteza zakładała przewagę CNN w klasyfikacji obrazów. Wynik potwierdza ją dla badanego przebiegu: wzrost accuracy o 0,0381 (3,81 pkt proc.), kosztem większej liczby parametrów i czasu trenowania. Nie jest to porównanie z wyrównaną liczbą parametrów.



Rysunek 2. Krzywe uczenia CNN dla Fashion-MNIST: funkcja straty i dokładność.

3.2. CIFAR-10: techniki poprawiające uogólnianie

Architektura	Accuracy test	Liczba parametrów
CNN bazowa	0,7080	356 810
CNN z BN i augmentacją	0,7817	551 914
Mini-ResNet	0,7977	309 994

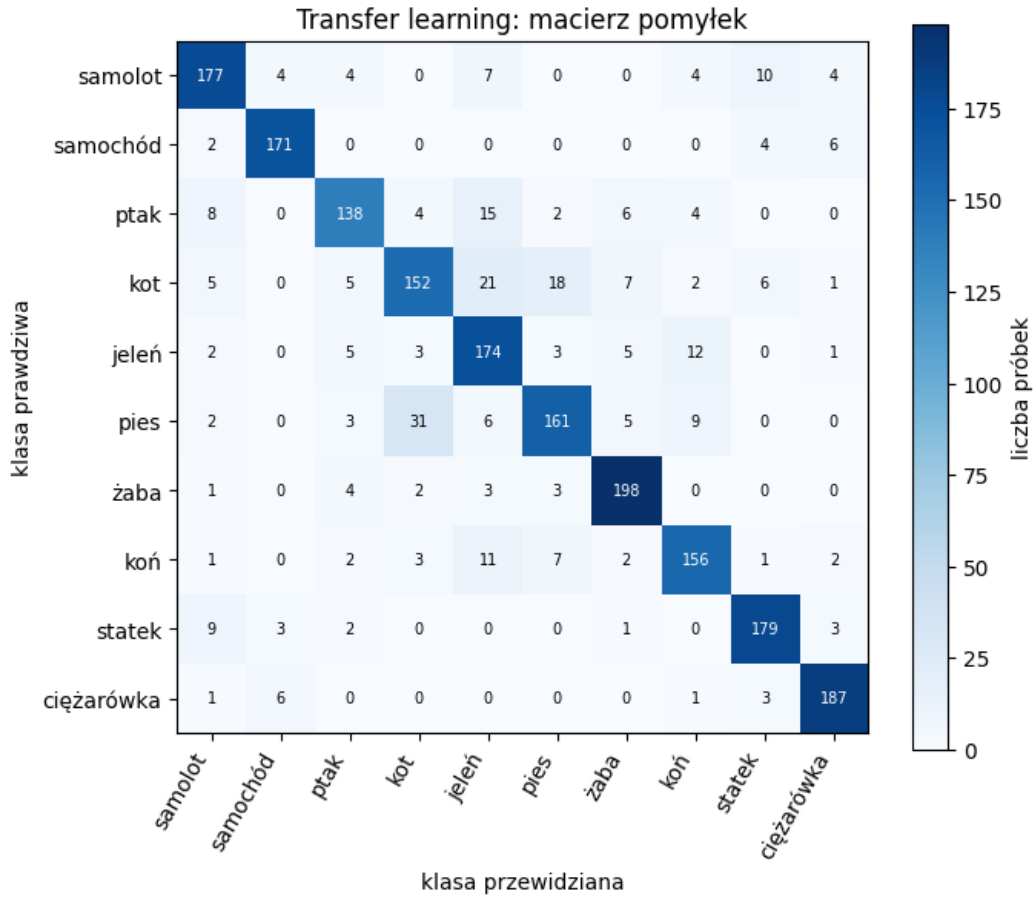
Dodanie BatchNormalization i augmentacji poprawiło wynik względem prostej CNN o 7,37 pkt proc. Mini-ResNet uzyskał dalszy niewielki wzrost accuracy. Krzywe szkoleniowe w notebooku wskazują, że augmentacja zmienia dynamikę uczenia i ogranicza prostą interpretację straty treningowej.

3 Laboratorium 04 — transfer learning (cd.)

3.3. MobileNetV2 na podzbiorze CIFAR-10

Model	Accuracy test	Rozmiar testu
MobileNetV2, baza zamrożona	0,8280	2 000
MobileNetV2, fine-tuning	0,8465	2 000

Odblokowanie wybranych warstw zwiększyło dokładność z 82,80% do 84,65% (+1,85 pkt proc.). Dla tych modeli wykorzystano jednak podzbiór 9 000 obserwacji treningowych i 2 000 testowych, a dla pozostałych CNN pełniejszy podział CIFAR-10 (45 000/10 000). Wyników między tymi dwoma grupami nie należy porównywać bez zastrzeżenia.



Rysunek 3. Macierz pomyłek MobileNetV2 po fine-tuningu (podzbiór testowy CIFAR-10).

Najtrudniejsze okazały się klasy wizualnie podobne, m.in. kot i pies (recall odpowiednio 0,70 i 0,74). Wysokie wyniki uzyskano dla samochodu i ciężarówki (recall 0,93 i 0,94). Mapy cech wskazują, że pierwsze warstwy reagują na lokalne krawędzie i tekstury, a głębsze tworzą bardziej zagregowane reprezentacje. Jako dalszy eksperyment można porównać obraz wejściowy 96×96 i 160×160 przy tej samej liczbie epok.

4 Laboratorium 05 — PyTorch i rzetelna ocena

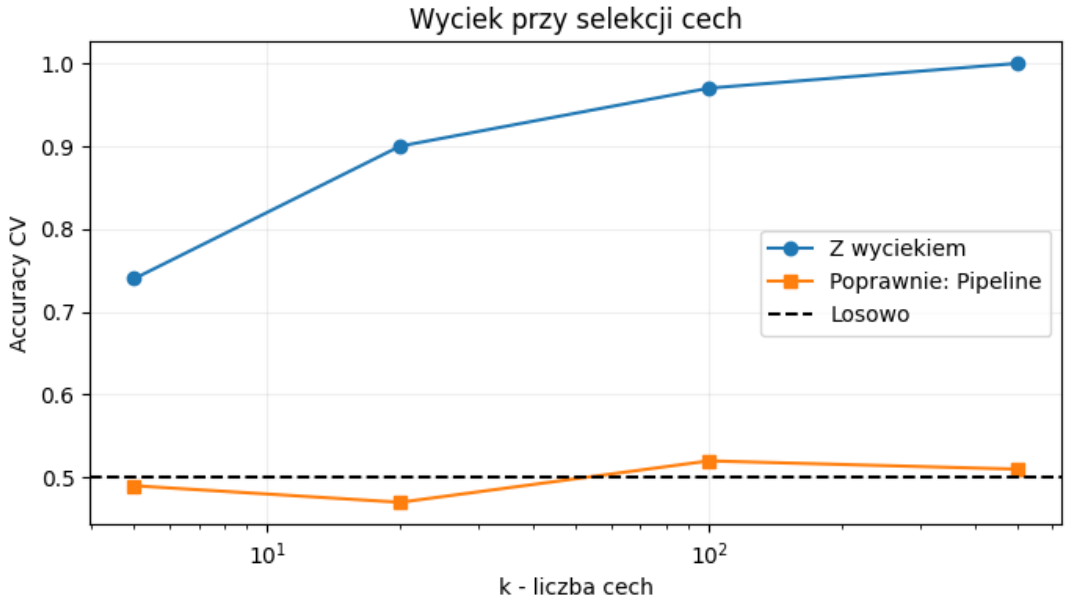
4.1. Klasyfikacja i regresja

Klasyfikator	ROC-AUC (val)	PR-AUC (val)	Brier (val)
Regresja logistyczna	0,9957	0,9946	0,0201
RandomForest	0,9916	0,9903	0,0283
HistGradientBoosting	0,9908	0,9879	0,0300
MLP	0,9954	0,9943	0,0164

Regresor (California Housing)	MAE test	RMSE test	R^2 test
Dummy	0,9053	1,1448	-0,0001
Ridge	0,5333	0,7495	0,5713
HistGB	0,3126	0,4675	0,8332
MLP	0,3396	0,5083	0,8028

W klasyfikacji MLP i regresja logistyczna osiągnęły zbliżony ROC-AUC; MLP uzyskał niższy Brier w walidacji. W regresji HistGB osiągnął najlepsze MAE i RMSE (w jednostkach celu: 100 tys. USD). Test ROC-AUC MLP wyniósł 0,9974, a 95% bootstrapowy przedział: [0,9907; 1,0000].

4.2. Niepewność, wyciek danych i kalibracja



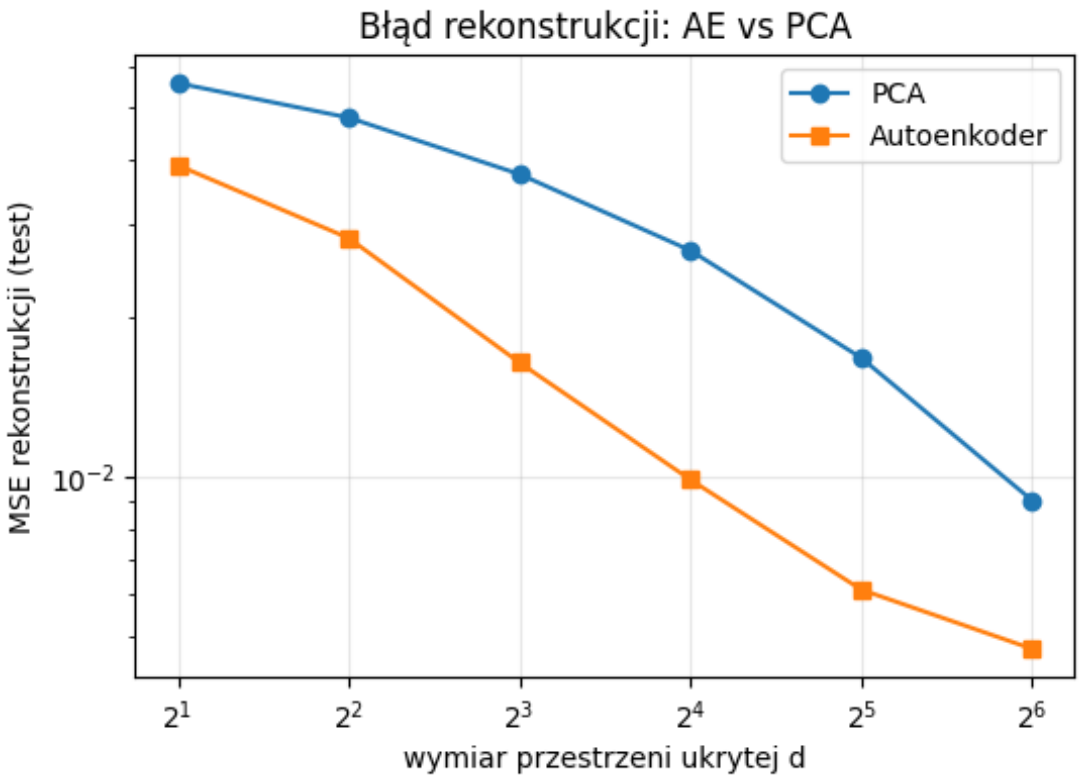
Rysunek 4. Pozorny wzrost accuracy po selekcji cech przed CV — przykład wycieku danych.

Dla poprawnej selekcji cech w ramach CV accuracy wyniosła ok. 0,47 (dla k = 20), zamiast wyniku 0,90 obserwowanego po niedozwolonej selekcji przed CV. Średnia różnica ROC-AUC MLP – LogReg w walidacji krzyżowej to -0,0003; skorygowany przedział dla różnicy [-0,00272; 0,00210] obejmuje zero. Dobór progu i kalibrację należy wykonywać bez podglądania testu.

5 Laboratorium 06 — PCA i autoenkodery

5.1. Wymiar reprezentacji i jakość rekonstrukcji

Dla MNIST do uzyskania 90% i 95% wyjaśnionej wariancji PCA potrzeba odpowiednio 87 i 154 składowych. Hipoteza, że nieliniowy autoenkoder może osiągać niższy MSE niż PCA przy tej samej liczbie wymiarów, potwierdziła się w analizowanych punktach.



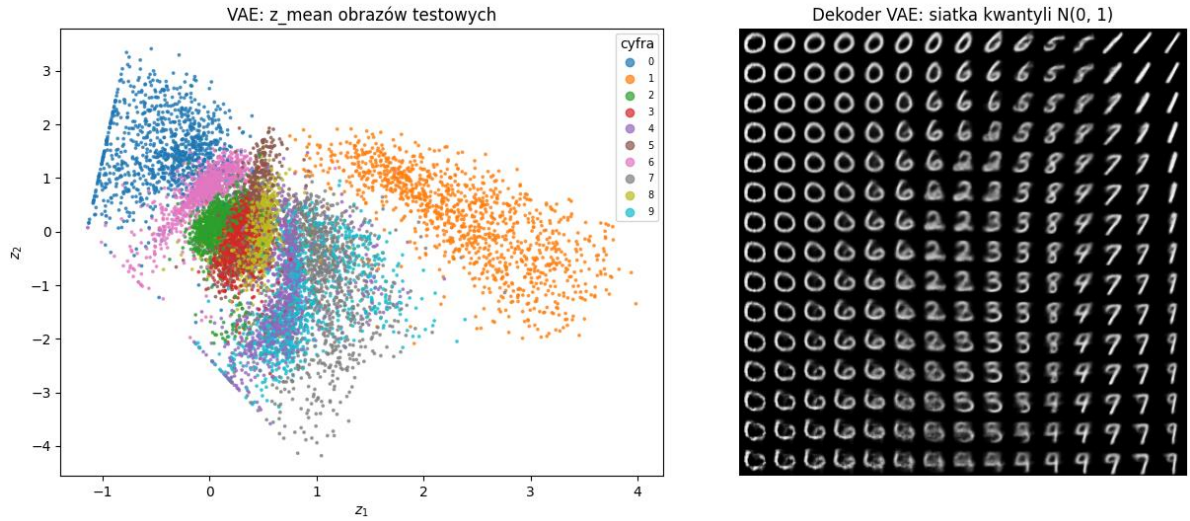
Rysunek 5. Błąd rekonstrukcji MSE w zależności od wymiaru: PCA a autoenkoder.

Reprezentacja	Wymiar	ARI	NMI
Piksele	784	0,414	0,512
PCA	32	0,408	0,508
AE	32	0,447	0,534
AE	2	0,279	0,505

W klasteryzacji k-means najwyższe ARI i NMI spośród zestawionych przestrzeni uzyskano dla AE 32. Sam wysoki silhouette dla AE 2 nie oznacza lepszej zgodności klas. W zadaniu detekcji anomalii ROC-AUC wynosił 0,639, a F1 0,072, co wskazuje na ograniczoną przydatność zastosowanego progu. Kolejny test: detektor oparty na CAE lub próg dobrany wyłącznie na walidacji.

6 Laboratorium 07 — VAE

6.1. Struktura przestrzeni latentnej



Rysunek 6. Latentna przestrzeń VAE (z_mean) i siatka próbek MNIST wygenerowanych przez dekoder.

Rozmieszczenie punktów odpowiadających cyfrom nie jest całkowicie rozdzielone, lecz tworzy obszary o różnym dominującym typie cyfry. Siatka dekodowanych obrazów pokazuje stosunkowo płynne przejścia między wzorcami, co wskazuje na ciągłość wyuczonej reprezentacji.

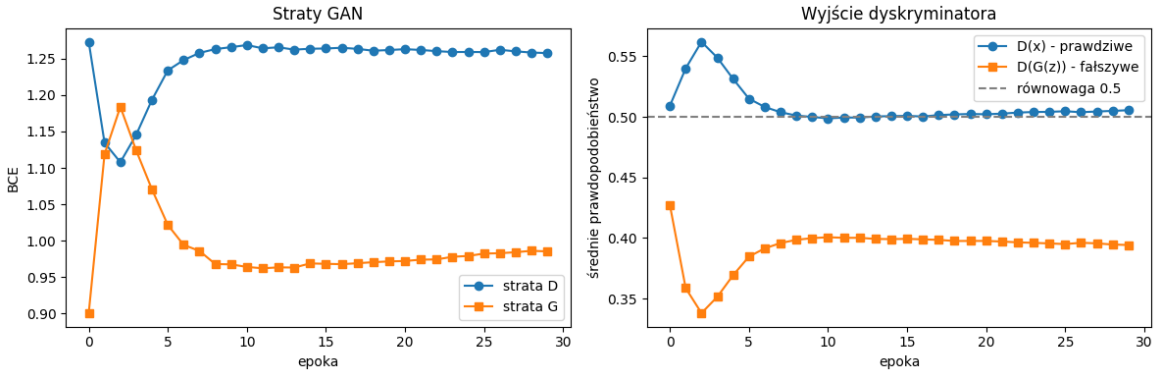
6.2. Wpływ parametru beta

β	Strata rekonstrukcji	Strata KL	SD(z_mean)
0,1	146,362	13,021	1,632
1,0	148,537	6,367	0,933
4,0	173,406	2,394	0,549

Hipoteza: wzrost wagi KL wzmacnia regularizację przestrzeni latentnej kosztem jakości rekonstrukcji. Strata KL maleje z 13,021 do 2,394, SD(z_mean) z 1,632 do 0,549, a strata rekonstrukcji rośnie z 146,362 do 173,406. Te wyniki wspierają hipotezę o kompromisie, ale same nie dowodzą zgodności pełnego rozkładu latentnego z priorem ani jakości wygenerowanych cyfr.

6 Laboratorium 07 — DCGAN (cd.)

6.3. Stabilność uczenia



Rysunek 7. Straty generatora i dyskryminatora oraz odpowiedzi dyskryminatora podczas treningu GAN.

Obie sieci optymalizowano naprzemiennie przez 30 epok. Wartości strat nie powinny być interpretowane jako bezpośrednia miara realizmu obrazów, ponieważ zależą także od bieżącej skuteczności przeciwnika. Wyniki trzeba konfrontować z generowanymi obrazami i miarami różnorodności [7].



Rysunek 8. Przykładowa ewolucja próbek generatora DCGAN dla stałego wektora szumu.

Entropia klas przewidzianych dla próbek GAN wyniosła 0,9887 wobec 0,9982 dla obrazów rzeczywistych; średnia pewność klasyfikatora wyniosła odpowiednio 0,7845 i 0,9135. Nie zaobserwowano wyraźnego całkowitego zaniku klas, ale te liczby nie wykluczają powtarzalności obrazów w obrębie klas (mode collapse częściowy).

7 Mini-projekt — problem i hipoteza

7.1. Problem badawczy i źródło danych

Problemem jest klasyfikacja binarna na zbiorze Breast Cancer Wisconsin (Diagnostic), dostępnym przez funkcję sklearn.datasets.load_breast_cancer. Dane zawierają 569 obserwacji, 30 cech liczbowych oraz dwie klasy: 212 i 357 przypadków. Jest to eksperyment dydaktyczny, nie system diagnostyczny do zastosowań klinicznych [5].

7.2. Hipoteza postawiona przed porównaniem

H_1: zastosowanie Dropout (p = 0,2) w sieci MLP zwiększy średni ROC-AUC na zbiorze testowym względem identycznej architektury MLP bez Dropout. Hipotezę weryfikowano w trzech niezależnych powtórzeniach (ziarna: 11, 42, 73).

7.3. Modele i warunki porównania

Element	Ustawienie
Baseline	Regresja logistyczna
MLP	30 → 32 (ReLU) → 16 (ReLU) → 1
Regularizacja	Dropout = 0 albo 0,2 po warstwach ukrytych
Optymalizator	Adam, learning rate = 0,003
Funkcja straty	BCEWithLogitsLoss
Budżet	100 epok, batch size = 64
Podział	60% trening, 20% walidacja, 20% test
Powtórzenia	3 ziarna: 11, 42, 73

7.4. Zapobieganie wyciekowi danych

Dla każdego ziarna utworzono podział warstwowy train/val/test. StandardScaler dopasowywano wyłącznie na zbiorze treningowym i stosowano bez ponownego dopasowania do walidacji i testu. Modele trenowano na tym samym treningu, a oceny końcowej dokonano na tym samym teście w danym powtórzeniu.

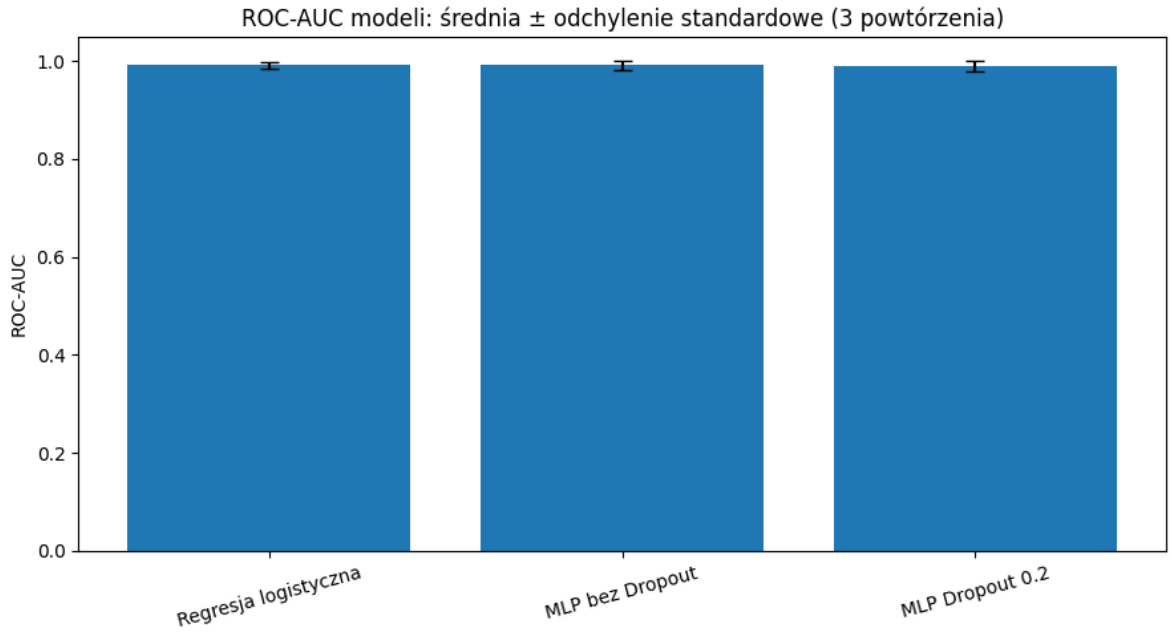
Źródło: wykonany notebook Mini_projekt_MLP_Dropout_Breast_Cancer.ipynb, komórki 0–7; bibliografia [2], [4], [5].

7 Mini-projekt — wyniki trzech powtórzeń

7.5. Metryki końcowe

Model	ROC-AUC (średnia ± SD)	Accuracy (śr. ± SD)	F1 (śr. ± SD)
Regresja logistyczna	0,9924 ± 0,0067	0,9737 ± 0,0152	0,9795 ± 0,0117
MLP bez Dropout	0,9915 ± 0,0098	0,9649 ± 0,0152	0,9723 ± 0,0118
MLP Dropout 0,2	0,9900 ± 0,0098	0,9620 ± 0,0268	0,9701 ± 0,0208

Najwyższą średnią wartość ROC-AUC (0,9924) uzyskała regresja logistyczna. Wersja MLP z Dropout nie przewyższyła wersji bez Dropout; różnica średniego ROC-AUC wyniosła -0,0015. Standardowe odchylenia obliczono pomiędzy trzema losowymi powtórzeniami, nie pomiędzy pojedynczymi pacjentami.



Rysunek 9. Średnia i rozrzut miar w trzech powtórzeniach — mini-projekt.

7.6. Interpretacja statystyczna

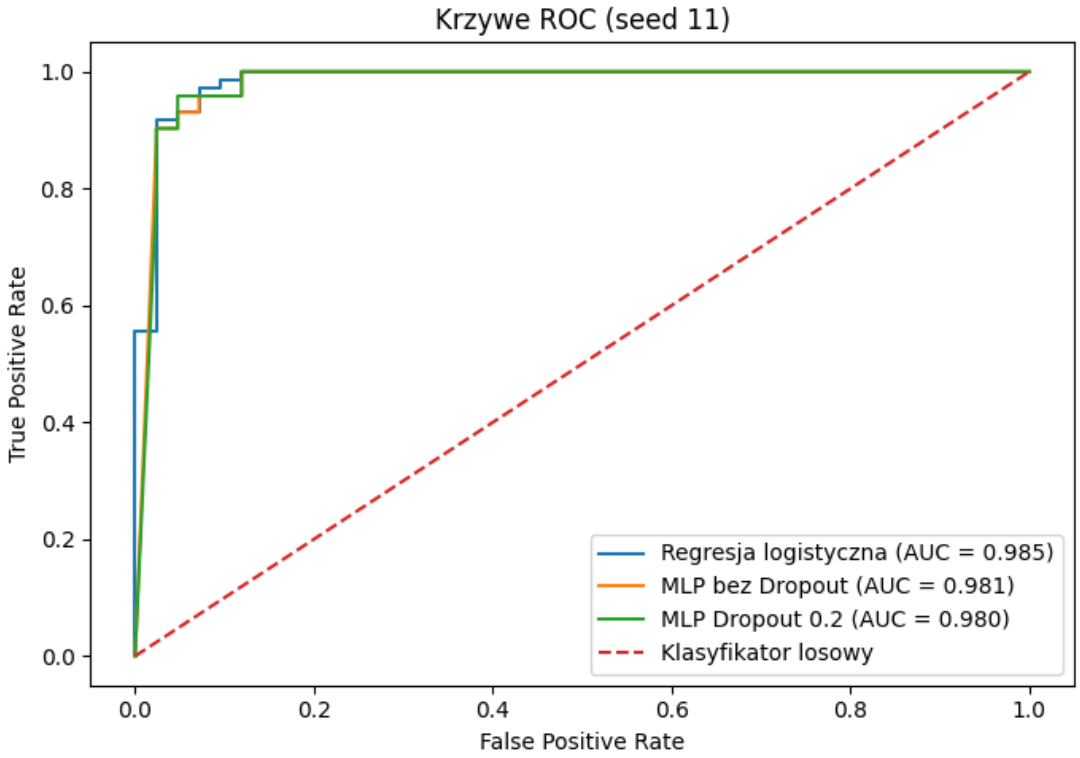
Mała liczba powtórzeń ogranicza moc wnioskowania. Wysokie ROC-AUC wszystkich modeli sugeruje, że zbiór jest stosunkowo łatwy dla zastosowanych metod, a ewentualna korzyść z Dropout może być mniejsza niż zmienność wynikająca z podziału danych. Nie przeprowadzano testu istotności, zatem nie wolno uznawać braku poprawy za dowód braku wpływu Dropout w ogólności.

7 Mini-projekt — szczegóły porównania

7.7. Wyniki w poszczególnych podziałach

Seed	LogReg ROC-AUC	MLP bez Dropout	MLP Dropout 0,2
11	0,9848	0,9808	0,9803
42	0,9950	0,9937	0,9897
73	0,9974	1,0000	1,0000

W dwóch pierwszych podziałach ROC-AUC modelu z Dropout było mniejsze od modelu bez Dropout; w trzecim obie sieci osiągnęły 1,0000. Dlatego wynik średni ma kierunek odwrotny do zakładanej hipotezy, mimo że dla jednego podziału modele były równoważne pod względem tej metryki.



Rysunek 10. Krzywe ROC trzech modeli na zbiorze testowym dla pierwszego powtórzenia.

7.8. Rozstrzygnięcie hipotezy (UGŁ_U01)

Hipoteza H_1 nie została potwierdzona w przeprowadzonych trzech powtórzeniach: średni ROC-AUC MLP z Dropout (0,9900) był o 0,0015 niższy niż MLP bez Dropout (0,9915). Nie oznacza to, że Dropout zawsze pogarsza jakość; w tym ustawieniu nie wniósł średniej korzyści przy przyjętej metryce i budżecie treningowym.

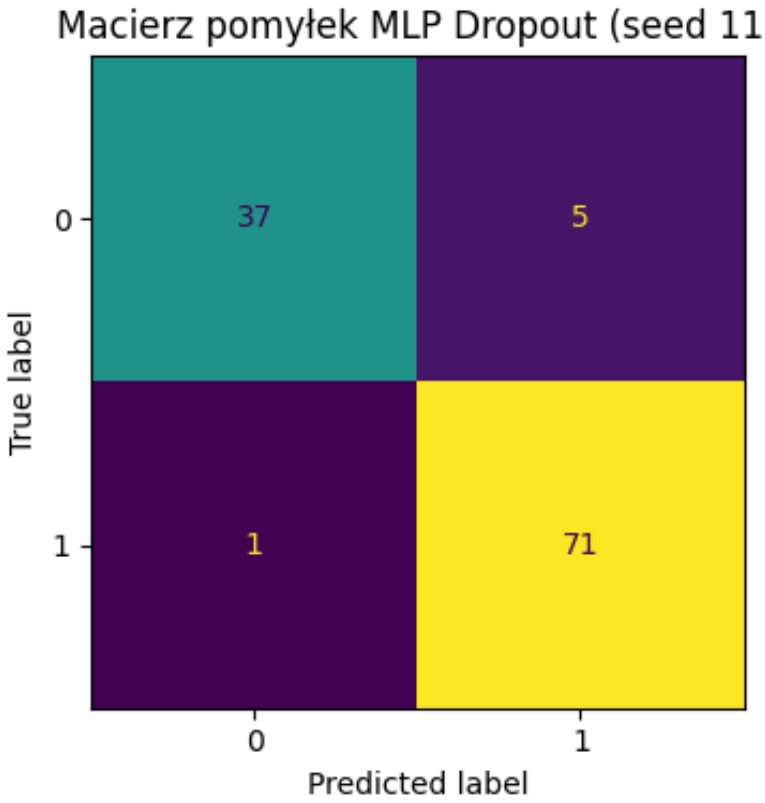
7 Mini-projekt — usprawnienie i ograniczenia

7.9. Eksperymentalne usprawnienie: próg decyzyjny

Jako usprawnienie (UGŁ_U02) sprawdzono wybór progu decyzji maksymalizującego F1 na zbiorze walidacyjnym. Próg wyszukiwano tylko w przedziale od 0,25 do 0,75 ze skokiem 0,05. Następnie tak wybrany próg zastosowano do predykcji na wcześniej wydzielonym teście.

Seed	Próg walidacyjny	F1 test, próg 0,50	F1 test, próg wybrany
11	0,25	0,9524	0,9595
42	0,25	0,9650	0,9722
73	0,50	0,9930	0,9930

Średnia zmiana F1 wyniosła +0,0048, czyli około 0,48 punktu procentowego. Poprawa dotyczy F1 przy konkretnym progu, nie ROC-AUC — ranking prawdopodobieństw modelu nie zmienił się.



Rysunek 11. Macierz pomyłek MLP z Dropout po wyborze progu na walidacji (seed = 11).

7.10. Ograniczenia projektu

Badanie dotyczy jednego, niewielkiego zbioru danych oraz jednej architektury sieci. Zmienność podziałów i inicjalizacji nie została rozdzielona na osobne czynniki; odchylenie standardowe z trzech uruchomień ma charakter orientacyjny. Dalszą analizę warto oprzeć na powtarzanej walidacji krzyżowej, kilku wartościach Dropout oraz większej liczbie ziaren.

8 Wnioski ogólne i ograniczenia

8.1. Najważniejsze obserwacje

- Lab 03: MLP osiągnął niższy MAE i RMSE niż regresja liniowa w analizowanym regresyjnym zadaniu California Housing. Dropout w badanym wariancie ograniczył lukę train–val względem BatchNorm.
- Lab 04: CNN przewyższyła MLP na Fashion-MNIST o 3,81 pkt proc. Fine-tuning MobileNetV2 poprawił wynik na użytym podzbiorze CIFAR-10 z 0,8280 do 0,8465.
- Lab 05: porównanie modeli tabelarycznych pokazało brak jednoznacznej przewagi MLP nad prostszymi metodami; selekcja cech wykonana przed CV silnie zawyża ocenę jakości.
- Lab 06: autoenkoder lepiej rekonstruował obrazy MNIST niż PCA przy porównywanym wymiarze reprezentacji; wynik detekcji anomalii był umiarkowany lub niski.
- Lab 07: wzrost beta w VAE wiązał się ze wzrostem straty rekonstrukcji i spadkiem miary rozproszenia latentnego. DCGAN tworzył zróżnicowane kategorie, lecz nie wykluczono częściowego mode collapse.
- Mini-projekt: hipoteza poprawy ROC-AUC przez Dropout nie znalazła wsparcia w trzech powtórzeniach; dobór progu na walidacji poprawił średni F1 o 0,0048.

8.2. Ograniczenia i dalsze działania

Wyniki zależą od podziałów, liczby epok, architektury, wersji bibliotek oraz sposobu doboru hiperparametrów. Część porównań dotyczy różnych podzbiorów danych, a modele generatywne oceniano również miarami pomocniczymi. Utrzymanie oddzielnego testu i procedur bez wycieku danych pozostaje warunkiem wiarygodnej interpretacji. Dalsze eksperymenty powinny obejmować dodatkowe powtórzenia, przedziały niepewności i testy na innych zbiorach.

8.3. Materiały źródłowe

Kod, wyniki komórek i wykresy wykorzystane w sprawozdaniu znajdują się w publicznym repozytorium: https://github.com/kapis55/Uczenie-Glebokie-I-jego-zastosowanie. Mini-projekt: Mini_projekt_MLP_Dropout_Breast_Cancer.ipynb. Przed wysłaniem należy sprawdzić dostępność linku w trybie prywatnym.

9 Bibliografia

[1] Goodfellow I., Bengio Y., Courville A. (2016), Deep Learning, MIT Press, https://www.deeplearningbook.org/.

[2] Srivastava N. i in. (2014), Dropout: A Simple Way to Prevent Neural Networks from Overfitting, Journal of Machine Learning Research, 15, 1929–1958, https://jmlr.org/papers/v15/srivastava14a.html.

[3] Paszke A. i in. (2019), PyTorch: An Imperative Style, High-Performance Deep Learning Library, NeurIPS 32, https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.

[4] Chollet F. i in., Keras Documentation, https://keras.io/ (dostęp 22.10.2026).

[5] scikit-learn Developers, load_breast_cancer — dokumentacja zbioru Breast Cancer Wisconsin (Diagnostic), https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html (dostęp 22.10.2026).

[6] Kingma D. P., Welling M. (2014), Auto-Encoding Variational Bayes, ICLR, https://arxiv.org/abs/1312.6114.

[7] Goodfellow I. i in. (2014), Generative Adversarial Nets, Advances in Neural Information Processing Systems 27, https://proceedings.neurips.cc/paper/2014/hash/f033ed80deb0234979a61f95710dbe25-Abstract.html.

10. Oświadczenie o samodzielności i użyciu narzędzi AI

Oświadczam, że zapoznałem się z przedstawionym opracowaniem, rozumiem opisane metody i mogę omówić przedstawione wyniki. Wykorzystałem ChatGPT (OpenAI) jako narzędzie pomocnicze przy uzupełnianiu i poprawianiu kodu, diagnozowaniu błędów i redakcji tekstu sprawozdania. Eksperymenty uruchomiono w Google Colab, a podane wyniki i wykresy pochodzą z zapisanych notebooków.

Oświadczenie wymaga osobistego przeczytania i potwierdzenia przez autora przed oddaniem.

Podpis autora: _____

Data: _____